

Fuzzy-GraphSMOTE

Une approche de suréchantillonnage pour le classement flou des nœuds
dans les graphes à données déséquilibrées

Gradi Kamingu Lubwele, M.Sc.

Faculté des Sciences et Technologies
Université de Kinshasa

Séminaire de recherche doctorale

31 juillet 2026

Plan de la présentation

1 Introduction

- Jeu des données (*Dataset*)
- Jeu des données à structure de graphe (*Graph dataset*)
- Quelques jeux de données graphes
- Présentation du problème

2 Méthodologie

- Idée
- Représentation de nœuds sous forme vectorielle
- Identification des nœuds minoritaires flous
- Entraînement du classifieur Fuzzy GNN

3 Expérimentations numériques

- Protocole expérimental
- Jeu de données
- Résultats et analyses

Plan de la présentation

1 Introduction

- Jeu des données (*Dataset*)
- Jeu des données à structure de graphe (*Graph dataset*)
- Quelques jeux de données graphes
- Présentation du problème

2 Méthodologie

- Idée
- Représentation de nœuds sous forme vectorielle
- Identification des nœuds minoritaires flous
- Entraînement du classifieur Fuzzy GNN

3 Expérimentations numériques

- Protocole expérimental
- Jeu de données
- Résultats et analyses

Introduction: Jeu des données (*Dataset*)

- Les données sont souvent se représenter simplement avec des tableaux (ou des matrices) de format $n \times p$:

$$\begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}$$

où x_i désigne la i -ème ligne, qui est un p -tuple donné par $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})$ et y_h désigne la h -ème colonne.

Terminologie

- Les colonnes y_h : **variables = attributs = caractéristiques = descripteurs = propriétés = champs.**

Terminologie

- Les colonnes y_h : **variables = attributs = caractéristiques = descripteurs = propriétés = champs.**
- Les lignes x_i : **individus = instances = objets = exemples = enregistrements = tuples = échantillons = données = cas.**

Terminologie

- Les colonnes y_h : **variables = attributs = caractéristiques = descripteurs = propriétés = champs.**
- Les lignes x_i : **individus = instances = objets = exemples = enregistrements = tuples = échantillons = données = cas.**
- Les coefficients x_{ih} : **valeur = cellule = observation = mesure = valeur d'attribut.**

Terminologie

- Les colonnes y_h : **variables = attributs = caractéristiques = descripteurs = propriétés = champs.**
- Les lignes x_i : **individus = instances = objets = exemples = enregistrements = tuples = échantillons = données = cas.**
- Les coefficients x_{ih} : **valeur = cellule = observation = mesure = valeur d'attribut.**

L'ensemble des individus est noté

$$\Omega = \{x_1, x_2, \dots, x_n\}.$$

Dans de nombreux problèmes d'apprentissage, Ω est supposé être un espace métrique.

Pourquoi dépasser les données tabulaires ?

Limite des représentations matricielles

Les données tabulaires décrivent essentiellement les attributs des individus, mais ne modélisent pas explicitement les relations entre eux.

Pourquoi dépasser les données tabulaires ?

Limite des représentations matricielles

Les données tabulaires décrivent essentiellement les attributs des individus, mais ne modélisent pas explicitement les relations entre eux.

Exemples

- Réseaux sociaux ;
- Réseaux de citation ;
- Réseaux de co-publication ;
- Réseaux de recommandation ;
- Réseaux biologiques.

Pourquoi dépasser les données tabulaires ?

Limite des représentations matricielles

Les données tabulaires décrivent essentiellement les attributs des individus, mais ne modélisent pas explicitement les relations entre eux.

Exemples

- Réseaux sociaux ;
- Réseaux de citation ;
- Réseaux de co-publication ;
- Réseaux de recommandation ;
- Réseaux biologiques.

⇒ Utiliser une représentation sous forme de graphe.

Définition d'un graphe

Définition (Graphe)

Un graphe G est un couple (X, E) où :

- X est un ensemble non vide et au plus dénombrable dont les éléments sont appelés *sommets* ou *nœuds* du graphe G ;
- E est une famille d'éléments du produit cartésien $X \times X = \{(x_i, x_j) | x_i, x_j \in X\}$. Les éléments de E sont appelés : *arcs* ou *arêtes* selon qu'ils sont orientés ou pas.

Quelques jeux de données graphes

Domaine	Dataset	Nœuds	Arêtes	Orientation
Citation	Cora	2708	5429	Oui
Citation	CiteSeer	3327	4732	Oui
Biomédical	PubMed	19717	44338	Oui
Réseau social	BlogCatalog	10312	333983	Non
Social	Karate Club	34	78	Non

Présentation du problème

- Un graphe utilisé pour la représentation de données peut adopter plusieurs configurations notamment,

Présentation du problème

- Un graphe utilisé pour la représentation de données peut adopter plusieurs configurations notamment,
 - ① les *graphes à nœuds attribués* ((Node-)Attributed Graphs),

Présentation du problème

- Un graphe utilisé pour la représentation de données peut adopter plusieurs configurations notamment,
 - ① les *graphes à nœuds attribués* (*(Node-)Attributed Graphs*),
 - ② les *graphes à arêtes attribuées* (*Edge-Attributed Graphs*),

Présentation du problème

- Un graphe utilisé pour la représentation de données peut adopter plusieurs configurations notamment,
 - ① les *graphes à nœuds attribués* (*(Node-)Attributed Graphs*),
 - ② les *graphes à arêtes attribuées* (*Edge-Attributed Graphs*),
 - ③ les *graphes entièrement attribués* (*Fully Attributed Graph*) (avec des attributs sur les nœuds et les arêtes),

Présentation du problème

- Un graphe utilisé pour la représentation de données peut adopter plusieurs configurations notamment,
 - ① les *graphes à nœuds attribués* (*(Node-)Attributed Graphs*),
 - ② les *graphes à arêtes attribuées* (*Edge-Attributed Graphs*),
 - ③ les *graphes entièrement attribués* (*Fully Attributed Graph*) (avec des attributs sur les nœuds et les arêtes), et
 - ④ les *graphes non attribués*.

Présentation du problème

- Un graphe utilisé pour la représentation de données peut adopter plusieurs configurations notamment,
 - ① les *graphes à nœuds attribués* ((Node-)Attributed Graphs),
 - ② les *graphes à arêtes attribuées* (Edge-Attributed Graphs),
 - ③ les *graphes entièrement attribués* (Fully Attributed Graph) (avec des attributs sur les nœuds et les arêtes), et
 - ④ les *graphes non attribués*.

Problématique

Dans ce travail, nous considérons un graphe à nœuds attribués $G = (V, E, X)$, où V est l'ensemble des sommets (nœuds), $E \subseteq \left\{ \{v_i, v_j\} \mid v_i, v_j \in V, v_i \neq v_j \right\}$ est l'ensemble des arêtes, $X \in \mathbb{R}^{|V| \times d}$ est la matrice des caractéristiques des nœuds et $A \in \mathbb{R}^{|V| \times |V|}$ désigne la matrice d'adjacence.

Les trois principales tâches d'apprentissage sur les graphes

Niveau	Problème / Définition	Exemple d'application
Nœuds	Classement des nœuds (Node Classification): Prédire l'étiquette des nœuds non étiquetés à partir du graphe $G = (V, E, X)$ et des nœuds étiquetés.	Prédire la catégorie d'un utilisateur d'un réseau social à partir de ses interactions et de son profil.
Arêtes	Prédiction des liens (Link Classification): Prédire l'existence d'une arête entre deux nœuds $\{u_i, u_j\}$ à partir du graphe $G = (V, E, X)$ et d'un sous-ensemble d'arêtes connues.	Recommander de nouvelles relations (" <i>Amis que vous pourriez connaître</i> ").
Graphes	Classement des graphes (Graph Classification): Prédire l'étiquette d'un graphe à partir d'un ensemble de graphes dont certains sont déjà étiquetés.	Prédire l'activité biologique ou la toxicité d'une molécule à partir de sa structure chimique.

Revenons au classement des nœuds

- Chaque ligne $\mathbf{X}[j, :] \in \mathbb{R}^{1 \times d}$ correspond au vecteur d'attributs (variables) du nœud v_j , où d est le nombre d'attributs. Soit $\mathbf{Y} \in \mathbb{R}^{|V|}$ le vecteur des étiquettes de classe des nœuds. L'ensemble des nœuds étiquetés est noté $V_L \subseteq V$, avec des étiquettes connues $\mathbf{Y}_L \subseteq \mathbf{Y}$, et l'ensemble des nœuds non étiquetés est $V_U = V \setminus V_L$, avec des étiquettes inconnues $\mathbf{Y}_U$.
- Supposons que les nœuds soient répartis en m classes distinctes $C_1, \dots, C_m \subseteq V$, où $|C_i|$ désigne le nombre de nœuds dans la classe C_i . Chaque nœud étiqueté appartient à une seule classe ; plus précisément, $v_j \in C_k$ si et seulement si $y_j = k$.

Observations

- Les données sont dites **déséquilibrées** lorsqu'au moins une classe est fortement sous-représentée, par exemple un ratio 90% – 10%.

Observations

- Les données sont dites **déséquilibrées** lorsqu'au moins une classe est fortement sous-représentée, par exemple un ratio 90% – 10%.
- Les classifieurs conventionnels tendent à privilégier la classe majoritaire **pour minimiser l'erreur globale**, ce qui réduit leur efficacité sur les classes minoritaires.

Observations

- Les données sont dites **déséquilibrées** lorsqu'au moins une classe est fortement sous-représentée, par exemple un ratio 90% – 10%.
- Les classifieurs conventionnels tendent à privilégier la classe majoritaire **pour minimiser l'erreur globale**, ce qui réduit leur efficacité sur les classes minoritaires.
- Pourtant, la **classe minoritaire** est parfois la plus importante, car les événements rares sont généralement ceux qui intéressent le plus.

Cas 1 : Non prise en compte des relations entre les individus

Méthodes de ré-échantillonnage

① Sur-échantillonnage:

- Sur-échantillonnage aléatoire;
- SMOTE [Chawla et al., 2002].

② Sous-échantillonnage:

- Sous-échantillonnage aléatoire;
- Liens de Tomek [?].

Méthodes algorithmiques

① Adaptation algorithmique:

- k-NN [Barandela et al., 2003];
- SVM [?].

② Méthodes de combinaison des classifieurs:

[Khoshgoftaar et al., 2015], [?]

Résolution du défi 1

Cas 1 : Non prise en compte des relations entre les individus

Méthodes de ré-échantillonnage

① Sur-échantillonnage:

- Sur-échantillonnage aléatoire;
- SMOTE [Chawla et al., 2002].

② Sous-échantillonnage:

- Sous-échantillonnage aléatoire;
- Liens de Tomek [?].

Méthodes algorithmiques

① Adaptation algorithmique:

- k-NN [Barandela et al., 2003];
- SVM [?].

② Méthodes de combinaison des classifieurs:

[Khoshgoftaar et al., 2015], [?]

Limitation

Ces approches ont été principalement développées pour les **données tabulaires**. Elles ne tiennent pas compte des **relations topologiques** entre les individus.

Cas 2 : Prise en compte des relations entre les individus

Année	Méthode
2021	GraphSMOTE
2022	GraphMixup
2022	GraphENS
2023	GATSMOTE

Cas 2 : Prise en compte des relations entre les individus

Année	Méthode
2021	GraphSMOTE
2022	GraphMixup
2022	GraphENS
2023	GATSMOTE

Ces approches :

- exploitent les embeddings des graphes ;
- génèrent de nouveaux nœuds synthétiques ;
- reconstruisent les arêtes.

Cas 2 : Prise en compte des relations entre les individus

Année	Méthode
2021	GraphSMOTE
2022	GraphMixup
2022	GraphENS
2023	GATSMOTE

Ces approches :

- exploitent les embeddings des graphes ;
- génèrent de nouveaux nœuds synthétiques ;
- reconstruisent les arêtes.

Limitation

Les étiquettes sont supposées **crisp**.

Deuxième défi : Imprécision des données

Observation

Les frontières entre les classes sont souvent imprécises. Un même nœud peut présenter des caractéristiques appartenant à plusieurs classes.

Deuxième défi : Imprécision des données

Observation

Les frontières entre les classes sont souvent imprécises. Un même nœud peut présenter des caractéristiques appartenant à plusieurs classes.

La théorie des ensembles flous fournit un cadre naturel pour modéliser cette incertitude [Zadeh, 1965][Kamingu, 2016].

Definition (Ensemble flou)

Soit X un ensemble de référence ou univers. Soit x un élément quelconque de X . On dit qu'une partie A de l'ensemble de référence X est un **ensemble flou** lorsqu'elle est définie de la manière suivante :

$$A = \{(x, \mu_{\tilde{A}}(x)) | x \in X\}, \quad (1)$$

avec : $\mu_{\tilde{A}} \longrightarrow [0, 1]$. Une partie A d'un ensemble X est usuellement associée à sa fonction d'appartenance.

Principe

La logique floue permet de représenter l'incertitude des frontières entre classes.

Principe

La logique floue permet de représenter l'incertitude des frontières entre classes.

Exemples :

- Fuzzy-SMOTE [Xu et al., 2017];
- Fuzzy SVM
[Lin and Wang, 2002, Batuwita and Palade, 2010, Fan et al., 2017];
- Fuzzy k-NN [Liu et al., 2013];
- Méthode de classement de données tabulaires à l'aide d'une graphe auxiliaire et du modèle flou [Chen et al., 2022].

Principe

La logique floue permet de représenter l'incertitude des frontières entre classes.

Exemples :

- Fuzzy-SMOTE [Xu et al., 2017];
- Fuzzy SVM
[Lin and Wang, 2002, Batuwita and Palade, 2010, Fan et al., 2017];
- Fuzzy k-NN [Liu et al., 2013];
- Méthode de classement de données tabulaires à l'aide d'une graphe auxiliaire et du modèle flou [Chen et al., 2022].

Limitation

Ces approches ignorent la structure topologique des graphes.

Les méthodes existantes :

- gèrent le déséquilibre des classes **ou**
- gèrent l'incertitude,

mais très peu traitent simultanément ces deux défis.

Les méthodes existantes :

- gèrent le déséquilibre des classes **ou**
- gèrent l'incertitude,

mais très peu traitent simultanément ces deux défis.

Objectif du travail

Développer une approche de suréchantillonnage flou capable de traiter simultanément le déséquilibre des classes et l'incertitude dans les graphes.

Comparaison des approches existantes

Méthode	Graphes	Déséquilibre	Logique floue
SMOTE	X	✓	X
GraphSMOTE	✓	✓	X
Fuzzy-SMOTE	X	✓	✓
Fuzzy-GraphSMOTE	✓	✓	✓

Comparaison des approches existantes


Méthode	Graphes	Déséquilibre	Logique floue
SMOTE	✗	✓	✗
GraphSMOTE	✓	✓	✗
Fuzzy-SMOTE	✗	✓	✓
Fuzzy-GraphSMOTE	✓	✓	✓

Constat

Aucune méthode existante ne traite simultanément :

Graphes
+
Classes déséquilibrées
+

Positionnement de notre contribution



Idée principale

Fusionner les avantages de l'apprentissage sur graphes, du suréchantillonnage et de la logique floue dans un cadre unifié.

Plan de la présentation

1 Introduction

- Jeu des données (*Dataset*)
- Jeu des données à structure de graphe (*Graph dataset*)
- Quelques jeux de données graphes
- Présentation du problème

2 Méthodologie

- Idée
- Représentation de nœuds sous forme vectorielle
- Identification des nœuds minoritaires flous
- Entraînement du classifieur Fuzzy GNN

3 Expérimentations numériques

- Protocole expérimental
- Jeu de données
- Résultats et analyses

L'idée de Fuzzy-GraphSMOTE [Kamingu et al., 2026] (Inspiré du GraphSMOTE[Zhao et al., 2021]) :

- ➊ **Apprentissage d'une représentation vectorielle des nœuds à l'aide d'un encodeur** → construction de l'espace latent de représentation ;
- ➋ **Génération de nœuds synthétiques dans la classe minoritaire, suivie de la génération des arêtes** → obtention d'un graphe augmenté et rééquilibré ;
- ➌ **Entraînement d'un Fuzzy GNN sur ce graphe augmenté** → obtention d'un classificateur Fuzzy GNN.

Étape 1 : Représentation de nœuds sous forme vectorielle

GraphSAGE ([Hamilton et al., 2017]):

$$x'_j = \sigma \left(W \cdot \text{CONCAT} \left(X[v_j, :], X^\top \cdot A[:, v_j] \right) \right), \quad (2)$$

où W est une matrice de poids, $\sigma(\cdot)$ est une fonction d'activation non linéaire (par exemple, ReLU), $X[v_j, :]$ désigne les attributs du nœud v_j , et $A[:, v_j]$ est la v_j -ème colonne de la matrice d'adjacence.




Figure: Exemple de fonctionnement de GraphSAGE

Étape 2 : Identification des nœuds minoritaires flous

- Déterminer les régions minoritaires floues pour chaque classe k :

$$\mathcal{F}_k = \{v_j \in V_L \mid \mu_{\tilde{C}_k}(v_j) < \theta\}$$

- **Notations :**

- V_L : ensemble des nœuds étiquetés
 - $\tilde{C}_k$: classe minoritaire k
 - $\mu_{\tilde{C}_k}(v_j)$: degré d'appartenance flou de v_j à la classe k
 - θ : seuil de minorité floue
- Objectif : cibler les nœuds sous-représentés pour générer des nœuds synthétiques.

Étape 2' : Génération de nœuds synthétiques

- Pour chaque nœud $v_i \in \mathcal{F}_k$:
 - ① Sélectionner k voisins avec $\mu_{\tilde{C}_k} > \theta_{\text{neighbor}}$.
 - ② Calculer le nombre de nœuds synthétiques :

$$N_i = \lceil \alpha(1 - \mu_{\tilde{C}_k}(v_i)) \rceil$$

- ③ Générer les embeddings :

$$x_{\text{syn}} = x'_i + \delta(x'_j - x'_i), \quad \delta \sim \mathcal{U}(0, 1)$$

- ④ Assigner le label flou interpolé :

$$\tilde{y}_{\text{syn}} = \frac{\mu_i \tilde{y}_i + \mu_j \tilde{y}_j}{\mu_i + \mu_j}$$

Étape 2" : Génération floue des arêtes

- Calcul de l'adjacence floue entre nœuds synthétiques et existants :

$$E_{ij} = \sigma(h_i^\top S h_j) \cdot \mu_i^{\text{minor}} \cdot \mu_j^{\text{minor}}$$

- **Notations :**

- h_i, h_j : embeddings finaux des nœuds
- S : matrice de similarité apprise
- σ : sigmoïde
- $\mu_i^{\text{minor}}, \mu_j^{\text{minor}}$: appartenance floue des nœuds à la minorité
- E_{ij} : poids flou de l'arête

- Fonction de perte floue pour les arêtes :

$$\mathcal{L}_{\text{edge}}^{\text{fuzzy}} = \sum_{i,j \in \tilde{V}} \mu_i^{(\text{minor})} \mu_j^{(\text{minor})} (E_{ij} - A_{ij}^{\text{aug}})^2$$

- $A^{\text{aug}} \in \{0, 1\}^{|\tilde{V}| \times |\tilde{V}|}$: matrice d'adjacence du graphe augmenté, définie par :

$$A_{ij}^{\text{aug}} = \begin{cases} A_{ij}, & v_i, v_j \in V \\ 0, & \text{sinon} \end{cases}$$

Étape 2'' : Construction du graphe augmenté

- Fusion des embeddings réels et synthétiques :

$$\tilde{X}' = \text{CONCAT}(X', X_{\text{synt}})$$

- Fusion des labels flous :

$$\tilde{Y}_L = \text{CONCAT}(\tilde{Y}_L, \tilde{Y}_{\text{synt}})$$

- Graphe final :

$$\tilde{G} = (\tilde{V}, \tilde{E}, \tilde{X}')$$

- $\tilde{V}$: nœuds réels + synthétiques $\tilde{E}$: arêtes floues $\tilde{X}'$: embeddings concaténés

Étape 3 : Entraînement du classifieur Fuzzy GNN

- Le graphe augmenté $\tilde{G}$ est soumis à un classifieur GNN (par ex. GraphSAGE + couche linéaire).
- Pour chaque nœud v_u , le réseau produit un vecteur de probabilités :

$$P_u \in [0, 1]^m, \quad P_u[c] = \text{probabilité prédite que } v_u \in \tilde{C}_c$$

- Loss de classification floue :

$$\mathcal{L}_{\text{node}}^{\text{fuzzy}} = - \sum_{v_u \in \tilde{V}_L} \sum_{c=1}^m \mu_{\tilde{C}_c}(v_u) \log P_u[c]$$

- Interprétation : les erreurs sont pondérées par le degré d'appartenance flou, ce qui étend la cross-entropy classique.

Étapes 3'' : Optimisation conjointe et prédiction

- **Optimisation conjointe** des paramètres θ, ϕ, φ :

$$\min_{\theta, \phi, \varphi} \mathcal{L}_{\text{node}}^{\text{fuzzy}} + \lambda \mathcal{L}_{\text{edge}}^{\text{fuzzy}}$$

avec $\lambda > 0$ contrôlant le compromis entre classification et reconstruction des arêtes.

- Méthode : gradient stochastique + backpropagation jusqu'à convergence ou early stopping.
- **Prédiction sur nœuds non étiquetés** $v \in V_U$:

$$\tilde{y}_v = f_{\varphi}(v) \quad (\text{vecteur flou de membership})$$

$$Y'_v = \arg \max_c \tilde{y}_{v,c} \quad (\text{optionnel, labels crisp})$$

Plan de la présentation

1 Introduction

- Jeu des données (*Dataset*)
- Jeu des données à structure de graphe (*Graph dataset*)
- Quelques jeux de données graphes
- Présentation du problème

2 Méthodologie

- Idée
- Représentation de nœuds sous forme vectorielle
- Identification des nœuds minoritaires flous
- Entraînement du classifieur Fuzzy GNN

3 Expérimentations numériques

- Protocole expérimental
- Jeu de données
- Résultats et analyses

Plan de la présentation

1 Introduction

- Jeu des données (*Dataset*)
- Jeu des données à structure de graphe (*Graph dataset*)
- Quelques jeux de données graphes
- Présentation du problème

2 Méthodologie

- Idée
- Représentation de nœuds sous forme vectorielle
- Identification des nœuds minoritaires flous
- Entraînement du classifieur Fuzzy GNN

3 Expérimentations numériques

- Protocole expérimental
- Jeu de données
- Résultats et analyses

Configuration expérimentale

- **Jeu de données** : Cora.
- **Baselines** : GCN, GraphSAGE, GraphSMOTE et autres méthodes de référence.
- **Métriques** : Accuracy, Balanced Accuracy, Macro-F1 et G-Mean.
- **Objectif** : évaluer l'apport de la logique floue dans un contexte de déséquilibre des classes.

- 2708 nœuds;
- 5429 arêtes;
- Chaque nœud : vecteur binaire de 1,433 dimensions (présence de mots dans un dictionnaire);
- Chaque publication appartient à l'une des 7 classes, regroupées en 2 métaclasses

$$G = (V, E, X)$$

Réseau de citations de publications scientifiques

Métaclasses

- C_1 : Logic and Theoretical Foundations (829)
- C_2 : Practical and Applied Methods (1879)

Métaclasse	Classe	Nbr de nœuds
Logic and theor. foundations	Theory	351
	Rule Learning	180
	Case-Based Reasoning	298
Practical and appl. methods	Neural Networks	818
	Probabilistic Methods	426
	Genetic Algorithms	351
	Reinforcement Learning	334

Objectif : Modéliser l'imprécision et le chevauchement naturel des classes.

- Chaque nœud v a un degré d'appartenance flou $\mu_{\tilde{C}_k}(v)$:

$$\mu_{C_i}(v) \in [0.7, 1], \quad \mu_{C_j}(v) \leq 0.3, \quad j \neq i$$

- Basé sur les voisins :

$$\mu_{\tilde{C}_i}(v) = \begin{cases} 1 - \varepsilon(v), & i = y(v) \\ \varepsilon(v), & \text{sinon} \end{cases}, \quad \varepsilon(v) = \alpha \frac{|\Gamma(v) \cap C_j|}{|\Gamma(v)|}$$

- Les degrés sont normalisés pour que leur somme soit égale à 1 :
 $\sum_k \mu_{\tilde{C}_k}(v) = 1.$
- Instances ambiguës : 5% des nœuds avec voisinage équilibré modifiés pour $\mu \in [0.45, 0.55]$.

Performance du classement avec Cora

Method	Accuracy (%)	Bal. Acc (%)	Macro F1 (%)	G-Mean (%)
SMOTE	84.49 ± 0.92	82.55 ± 0.57	83.09 ± 0.82	82.19 ± 0.48
ADASYN	83.65 ± 1.62	81.30 ± 1.56	82.02 ± 1.68	80.77 ± 1.59
Borderline-SMOTE	83.39 ± 1.40	80.89 ± 1.93	81.66 ± 1.69	80.26 ± 2.17
Fuzzy-SMOTE	85.75 ± 1.10	84.83 ± 1.29	84.76 ± 1.20	84.74 ± 1.32
GraphSMOTE	92.04 ± 1.09	91.70 ± 1.23	91.51 ± 1.15	91.67 ± 1.25
GATS-MOTE	91.75 ± 0.80	91.60 ± 0.64	91.24 ± 0.75	91.58 ± 0.65
GraphSR	91.45 ± 1.10	90.81 ± 1.03	90.85 ± 1.11	90.77 ± 1.04
IM-GAN	93.59 ± 1.00	93.83 ± 0.92	93.23 ± 1.01	93.82 ± 0.92
GraphMixup	94.70 ± 0.84	94.50 ± 0.81	94.35 ± 0.83	94.50 ± 0.81
GraphENS	94.62 ± 0.85	94.37 ± 0.87	94.26 ± 0.85	94.37 ± 0.87
Fuzzy-GraphSMOTE	94.77 ± 0.84	94.26 ± 0.82	94.39 ± 0.85	94.24 ± 0.83

Figure: Performance de Fuzzy-GraphSMOTE vs baselines.

Principaux résultats

- Accuracy : **94.77%**
- Balanced Accuracy : **94.26%**
- Macro-F1 : **94.39%**
- G-Mean : **94.24%**

Principaux résultats

- Accuracy : **94.77%**
- Balanced Accuracy : **94.26%**
- Macro-F1 : **94.39%**
- G-Mean : **94.24%**

Observation

Fuzzy-GraphSMOTE améliore GraphSMOTE de 2.73 points en Accuracy et obtient les meilleures performances globales.

Que montrent réellement ces résultats ?

- **Accuracy (94.77%)** montre que notre modèle est performant sur l'ensemble du graphe.
- **Balanced Accuracy (94.26%)** indique que cette performance n'est pas obtenue au détriment des classes minoritaires, ce qui est essentiel dans un contexte de données déséquilibrées.
- **Macro-F1 (94.39%)** confirme que le modèle conserve un excellent équilibre entre précision et rappel pour toutes les classes, y compris les plus rares.
- **G-Mean (94.24%)** montre que les performances restent homogènes sur l'ensemble des classes, traduisant une bonne robustesse face au déséquilibre.
- Ainsi, les résultats expérimentaux montrent que l'intégration conjointe des **embeddings de graphes**, du **suréchantillonnage** et de la **logique floue** permet d'améliorer simultanément les performances globales et la classification des classes minoritaires.

Composant supprimé	Variation Macro-F1
Structure du graphe	-0.0968
Logique floue	-0.0276
Suréchantillonnage	-0.0017
Edge Generator	Impact mineur
Pré-entraînement	Impact mineur

La structure du graphe et la logique floue constituent les composantes les plus importantes.

Que montre l'étude d'ablation ? (001)

- La suppression de la **structure du graphe** entraîne la plus forte baisse du Macro-F1 (-0.0968). Cela montre que les relations entre les nœuds constituent la principale source d'information pour apprendre des représentations discriminantes.
- La suppression de la **logique floue** provoque également une dégradation notable (-0.0276). Ce résultat confirme que la modélisation de l'incertitude améliore la classification des nœuds situés aux frontières des classes, en particulier pour les classes minoritaires.
- Le **suréchantillonnage** présente un impact plus limité (-0.0017). Cela indique que son efficacité provient principalement de son interaction avec les représentations apprises par le GNN et les degrés d'appartenance flous, plutôt que de la simple génération de nouveaux nœuds.

Que montre l'étude d'ablation ? (002)

- Enfin, le **générateur d'arêtes** et le **pré-entraînement** ont une contribution plus faible, suggérant que les principaux gains proviennent de la combinaison entre la structure du graphe et la logique floue.

Message principal

Les performances de Fuzzy-GraphSMOTE reposent essentiellement sur deux piliers :

Structure du graphe + **Logique floue**

Le suréchantillonnage joue un rôle de renforcement en améliorant la représentation des classes minoritaires.

Étape	Complexité
Apprentissage des embeddings	Dépend du GNN
Suréchantillonnage	$O(n^2)$
Génération des arêtes	$O(E)$
Entraînement final	Dépend du GNN

Limitations

- Classification binaire.
- Graphes statiques.
- Seuil fixé manuellement.
- Passage à l'échelle.

Perspectives

- Seuil adaptatif.
- Multi-classes.
- Graphes dynamiques.
- Étude théorique des memberships.

Conclusion

- Les résultats valident l'efficacité de Fuzzy-GraphSMOTE.
- La logique floue améliore la gestion des classes minoritaires.
- La combinaison **GNN + suréchantillonnage + logique floue** produit les meilleures performances sur Cora.

References I

-  Barandela, R., Sanchez, J. S., Garcia, V., and Rangel, E. (2003). Strategies for learning in class imbalance problems. *Pattern Recognition*, 36(3):849–851.
-  Batuwita, R. and Palade, V. (2010). FSVM-CIL: Fuzzy Support Vector Machines for Class Imbalance Learning. *IEEE Transactions on Fuzzy Systems*, 18(3):558–571.
-  Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16:321–357. Originally published in 2002; arXiv version available (2011-06-09).

References II

-  Chen, B., Fan, Y., Lan, W., Liu, J., Cao, C., and Gao, Y. (2022). Fuzzy support vector machine with graph for classifying imbalanced datasets. *Neurocomputing*, 514:512–525.
-  Fan, Q., Wang, Z., Li, D., Gao, D., and Zha, H. (2017). Entropy-based fuzzy support vector machine for imbalanced datasets. *Knowledge-Based Systems*, 115:87–99.
-  Hamilton, W., Ying, Z., and Leskovec, J. (2017). Inductive representation learning on large graphs. In Guyon, I., Luxburg, U. V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., and Garnett, R., editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc.

References III



Kamingu, G. L. (2016).

Théorie des ensembles flous. caractérisation, propriétés et opérations.
One Pager Laréq, 11(1):37–45.



Kamingu, G. L., Kafunda, P. K., and Mbangu, E. N. (2026).

Fuzzy-GraphSMOTE: An Oversampling-Based Approach for Fuzzy
Node Classification in Imbalanced Graphs.

To be precised.

To appear.



Khoshgoftaar, T., Fazelpour, A., and Napolitano, D. J. D. A. (2015).

Learning to model the tail.

*IEEE 27th International Conference on Tools with Artificial
Intelligence.*



Lin, C.-F. and Wang, S.-D. (2002).

Fuzzy support vector machines.

IEEE Transactions on Neural Networks, 13(2):464–471.



Liu, Z., Cao, H., Chen, X., et al. (2013).

Multi-fault classification based on wavelet svm with pso algorithm to analyse vibration signals from rolling element bearings.

Neurocomputing, 99(1):399–410.



Xu, Y., Wu, C., Zheng, K., Niu, X., and Yang, Y. (2017).

Fuzzy-synthetic minority oversampling technique: Oversampling based on fuzzy set theory for Android malware detection in imbalanced datasets.

International Journal of Distributed Sensor Networks,
13(4):1550147717703116.



Zadeh, L. A. (1965).

Fuzzy sets.

Information and Control, 8(3):338–353.



Zhao, T., Zhang, X., and Wang, S. (2021).

GraphSMOTE: Imbalanced Node Classification on Graphs with Graph Neural Networks.

In *Proceedings of the 14th ACM International Conference on Web Search and Data Mining (WSDM)*, pages 833–841.